SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I INFORMACIJSKIH TEHNOLOGIJA OSIJEK

Projektna dokumentacija

DETEKCIJA UPALE PLUĆA IZ RENDGENSKIH SNIMKI

(KLASIFIKACIJA MEDICINSKIH SLIKA)

Konstrukcijske vježbe iz kolegija:

Strojno učenje

Tomislav Perković

Osijek, 2026.

SADRŽAJ

1. Uvod 2

2. Pregled postojećih rješenja 3

2.1. Pristranost podataka, učenje prečica i neželjeni artefakti 3
2.2. Konvolucijske neuronske mreže 3
2.3. Transfer učenje 3
2.4. *Grad-CAM* 3

3. Prijedlog vlastitog rješenja 4

3.1. Arhitektura sustava 4
3.2. Skup podataka 5
3.3. Predobrada slika 5
3.4. Korišteni modeli 6
3.5. Aplikacija i *Grad-CAM* prikaz 6

4. Rezultati testiranja 8

4.1. Postupak treniranja i evaluacije 8
4.2. Metrike evaluacije 8
4.3. Usporedba matrica konfuzije i ROC krivulja modela 9
4.4. Usporedba metrika modela 10
4.5. Usporedba *Grad-CAM* rezultata modela 10
4.6. Ograničenja sustava 11

5. Zaključak. 12

LITERATURA 13

1. UVOD

Klasifikacija medicinskih slika smatra se ključnom primjenom dubokog učenja u području računalnog vida. U ovom radu analizira se detekcija upale pluća iz rendgenskih snimki prsnog koša kao problem binarne klasifikacije, pri čemu se svaka ulazna snimka razvrstava u jednu od dvije klase, gdje vrijednost 0 označava klasu *NORMAL*, odnosno normalan nalaz, a vrijednost 1 klasu *PNEUMONIA*, odnosno upalu pluća.

Ovaj rad obuhvaća razvoj i evaluaciju modela dubokog učenja za automatsku analizu radioloških nalaza kroz izravnu usporedbu dvaju različitih pristupa. Uspoređuju se vlastita konvolucijska neuronska mreža trenirana od nule i unaprijed istrenirana arhitektura *VGG16* u sklopu transfer učenja. Time se provodi usporedba modela koji sve vizualne značajke uči izravno iz dostupnih medicinskih slika s modelom koji kroz transfer učenje prilagođava već naučene opće vizualne strukture.

Poseban naglasak stavljen je na evaluacijske metrike koje imaju kritičnu važnost u medicinskoj dijagnostici. Uz ukupnu točnost, sustav se vrednuje pomoću odziva, specifičnosti, preciznosti, F1-mjere, *AUC* vrijednosti i matrice konfuzije. Razvijenim modelom prvenstveno se teži minimizaciji lažno negativnih rezultata kako snimka s upalom pluća ne bi bila pogrešno klasificirana kao uredan nalaz.

Za interpretaciju odluke neuronske mreže koristi se metoda *Grad-CAM* kojom se generira toplinska karta područja slike s najvećim utjecajem na konačnu predikciju. Ovim postupkom omogućuje se jasna provjera fokusira li se model na relevantne dijelove pluća ili se pak odluka donosi na temelju neželjenih artefakata na slici.

2. PREGLED POSTOJEĆIH RJEŠENJA

2.1. Pristranost podataka, učenje prečica i neželjeni artefakti

Primjena dubokog učenja u medicinskoj analizi slika ne ovisi samo o arhitekturi modela, nego i o kvaliteti i reprezentativnosti skupa podataka. Ako podatci sadrže sustavne razlike između klasa koje nisu izravno povezane s bolešću, model može naučiti prepoznavati te sekundarne obrasce umjesto stvarnih medicinskih obilježja. Takvo ponašanje poznato je kao učenje prečica (engl. *shortcut learning*) ili *Clever Hans* efekt [1], pri čemu se prividno visoka točnost postiže na temelju posrednih znakova poput kontrasta, tekstualnih oznaka, rubova slike, položaja pacijenta ili vrste uređaja.

Zbog opasnosti od slabije generalizacije na novim izvorima podataka, numeričke metrike potrebno je nadopuniti provjerom načina donošenja odluke. U ovom radu taj se problem ublažava ujednačenom predobradom slika, augmentacijom podataka, odabirom praga odluke na validacijskom skupu i analizom *Grad-CAM* toplinskih karata. Time se provjerava oslanja li se model na relevantne anatomske regije ili na neželjene artefakte na slici.

2.2. Konvolucijske neuronske mreže

Konvolucijske neuronske mreže automatski uče vizualne značajke izravno iz ulaznih slika. Niži slojevi prepoznaju jednostavne strukture poput rubova i tekstura, dok dublji slojevi uče složenije obrasce. Kod rendgenskih snimki prsnog koša ti obrasci obuhvaćaju zamućenja i infiltrate u plućnom tkivu povezane s upalom pluća. Vlastita *CNN* arhitektura trenirana od nule omogućuje potpunu prilagodbu konkretnom zadatku, ali ujedno nosi veći rizik od prenaučenosti kada je skup podataka ograničen, neuravnotežen ili nedovoljno raznolik.

2.3. Transfer učenje

Transfer učenje koristi modele unaprijed istrenirane na velikim skupovima slika opće namjene, poput *ImageNet* skupa [2]. Budući da takvi modeli već sadrže naučena opća vizualna obilježja, njihovom se prilagodbom postižu stabilniji rezultati i brža konvergencija u uvjetima ograničenog broja označenih medicinskih slika. U ovom se radu transfer učenje primjenjuje na arhitekturi *VGG16* [3].

2.4. *Grad-CAM*

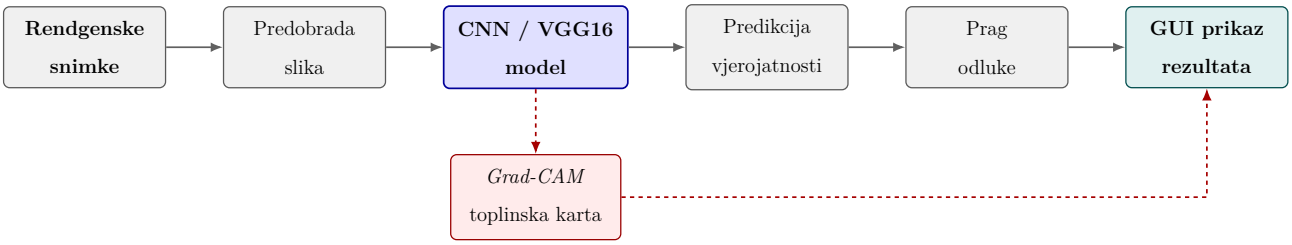
U medicinskim primjenama računalnog vida sama konačna predikcija nije dovoljna, jer je važno razumjeti na temelju kojih dijelova slike model donosi odluku. Metoda *Grad-CAM* (*Gradient-weighted Class Activation Mapping*) [4] omogućuje takvu interpretaciju generiranjem toplinske karte koja prikazuje područja slike s najvećim utjecajem na konačnu predikciju. Kod detekcije upale pluća poželjno je da se naglašena područja nalaze unutar plućnih krila. Ako toplinska karta ističe rubove slike, tekstualne oznake ili područja izvan pluća, to može upućivati na donošenje odluke na temelju neželjenih artefakata.

3. PRIJEDLOG VLASTITOG RJEŠENJA

3.1. Arhitektura sustava

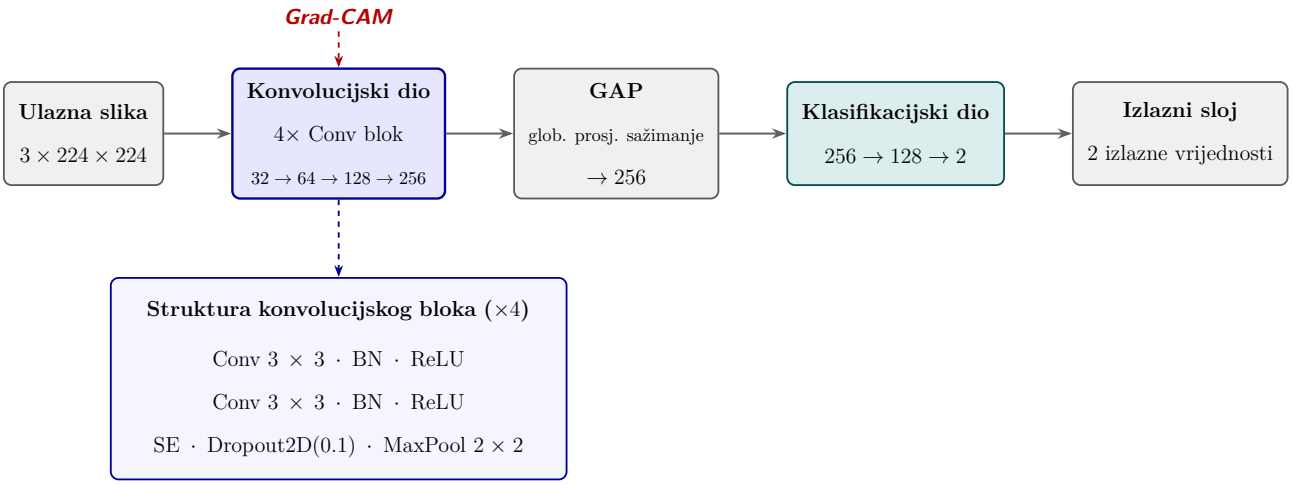
Predloženi sustav izveden je modularno radi jasnog razdvajanja funkcionalnosti treniranja modela, evaluacije, inferencije i korisničkog sučelja. Datoteka `main.py` objedinjuje glavnu logiku, uključujući konfiguraciju, učitavanje podataka, predobradu slika, definiciju modela, inferenciju, generiranje *Grad-CAM* toplinskih karata i pohranu rezultata. Modul `treniranje.py` koristi se za treniranje modela, `evaluacija.py` za izračun metrika i vizualizaciju grafova, dok je `gui.py` zadužen za korisničko sučelje.

Na slici 3.1 prikazan je osnovni tok rada sustava. Kao ulaz koristi se rendgenska snimka prsnog koša, nakon čega se provodi predobrada slike i priprema ulaznog tenzora za odabrani model. Odabrani model zatim provodi klasifikaciju i generira vjerojatnosti pripadnosti klasama *NORMAL* i *PNEUMONIA*. Konačna odluka donosi se usporedbom s definiranim pragom odluke, a rezultat se prikazuje u sučelju zajedno s pripadajućom *Grad-CAM* toplinskom kartom.



Slika 3.1: *Blok dijagram sustava za detekciju upale pluća.*

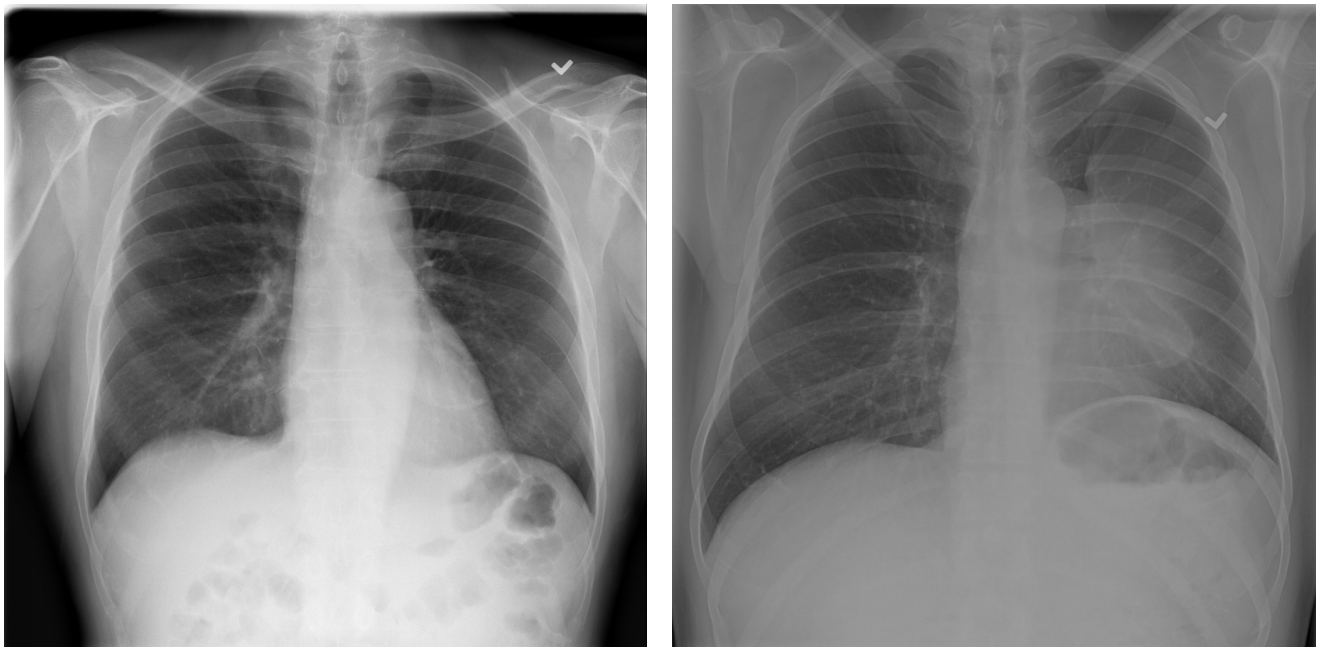
Na slici 3.2 prikazana je arhitektura predloženog *CNN* modela. Mreža obuhvaća četiri konvolucijska bloka kroz koje se broj kanala povećava od 32 do 256, uz smanjenje prostorne rezolucije s 112×112 na 14×14 piksela. Svaki blok sadrži dvije konvolucijske operacije s jezgrama 3×3, normalizaciju po seriji, aktivacijsku funkciju *ReLU*, *SE* mehanizam [5], *Dropout2D* sloj i sažimanje pomoću *MaxPool* sloja. Izdvajanje značajki dovršava se globalnim prosječnim sažimanjem, nakon čega slijedi završni klasifikacijski dio mreže.



Slika 3.2: *Blok dijagram vlastite konvolucijske neuronske mreže.*

3.2. Skup podataka

Za razvoj sustava koristi se javno dostupan skup podataka *RSNA Pneumonia Detection Challenge* s platforme *Kaggle* [6]. U sklopu navedenog skupa obuhvaćen je velik broj rendgenskih snimki prsnog koša razvrstanih na normalne nalaze i nalaze s upalom pluća. Zbog opsežnosti izvornog skupa podataka primjenjuje se njegov veći, uravnoteženi podskup s podjednakim brojem snimki unutar obje klase. Odabrane snimke podijeljene su na dijelove za treniranje, validaciju i testiranje. Klasa *PNEUMONIA* definirana je kao pozitivna s vrijednošću 1, dok je klasa *NORMAL* definirana kao negativna klasa s vrijednošću 0. Takva podjela omogućuje izračun metrika važnih za medicinsku klasifikaciju, posebno odziva i specifičnosti. Primjeri snimki prikazani su na slici 3.3.



Slika 3.3: *Primjeri rendgenskih snimki: lijevo normalna snimka, desno upala pluća.*

3.3. Predobrada slika

Prije obrade u modelu sve snimke prolaze kroz postupak ujednačavanja formata. Slike se pretvaraju u trokanalni oblik te se skaliraju i izrezuju na rezoluciju 224×224 piksela, nakon čega se provodi normalizacija vrijednosti piksela prema standardnim srednjim vrijednostima i standardnim devijacijama.

Za potrebe validacije i inferencije primjenjuje se deterministička obrada. Snimka se najprije skalira na nešto veću dimenziju, a zatim se izrezuje njezin središnji dio. Time se smanjuje utjecaj rubova slike, tekstualnih oznaka i drugih artefakata izvan primarnog plućnog područja, u skladu s ranije opisanim problemom učenja prečica.

Tijekom treniranja dodatno se primjenjuje umjerena augmentacija podataka radi povećanja robusnosti modela. Augmentacija obuhvaća nasumično izrezivanje, zrcaljenje, rotaciju, promjenu svjetline i kontrasta te nasumično brisanje dijelova slike. Pritom se vodi računa da se intenzitet transformacija drži unutar umjerenih granica kako ne bi došlo do narušavanja ključnih dijagnostičkih obilježja na snimci.

3.4. Korišteni modeli

U sklopu sustava evaluiraju se dva modela. Prvi model predstavlja vlastita *CNN* arhitektura trenirana od nule, sastavljena od više konvolucijskih blokova, slojeva normalizacije, *ReLU* aktivacija, slojeva sažimanja, globalnog prosječnog sažimanja te završnih potpuno povezanih slojeva.

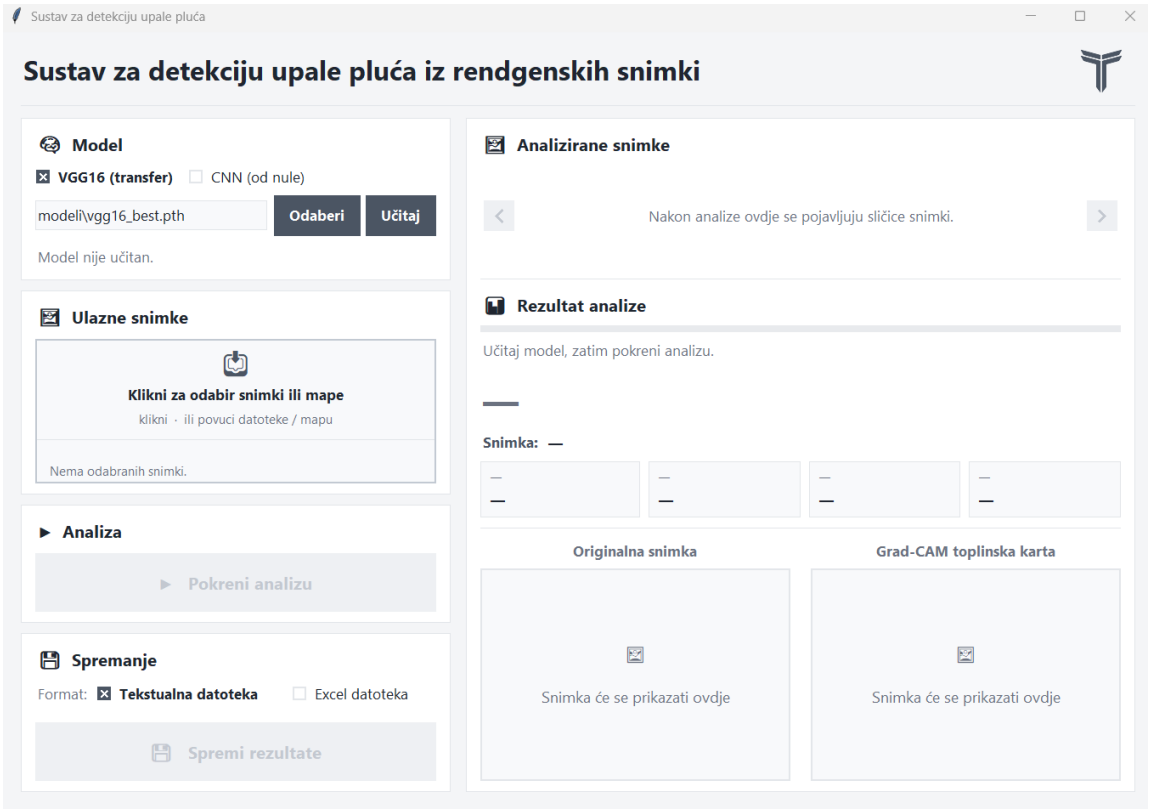
Drugi pristup koristi model *VGG16* u sklopu transfer učenja. Kod tog modela zadržava se unaprijed istrenirana konvolucijska baza, dok se originalni klasifikacijski dio zamjenjuje novim slojem prilagođenim za dvije klase, pri čemu se u drugoj fazi treniranja provodi i fino ugađanje zadnjeg konvolucijskog bloka.

Proces treniranja za oba modela uključuje metode regularizacije i smanjenja prenaučenosti, poput augmentacije podataka, *Dropout* slojeva, *weight decay* regularizacije, ranog zaustavljanja i balansiranja klasa pomoću prilagođenog uzorkovanja.

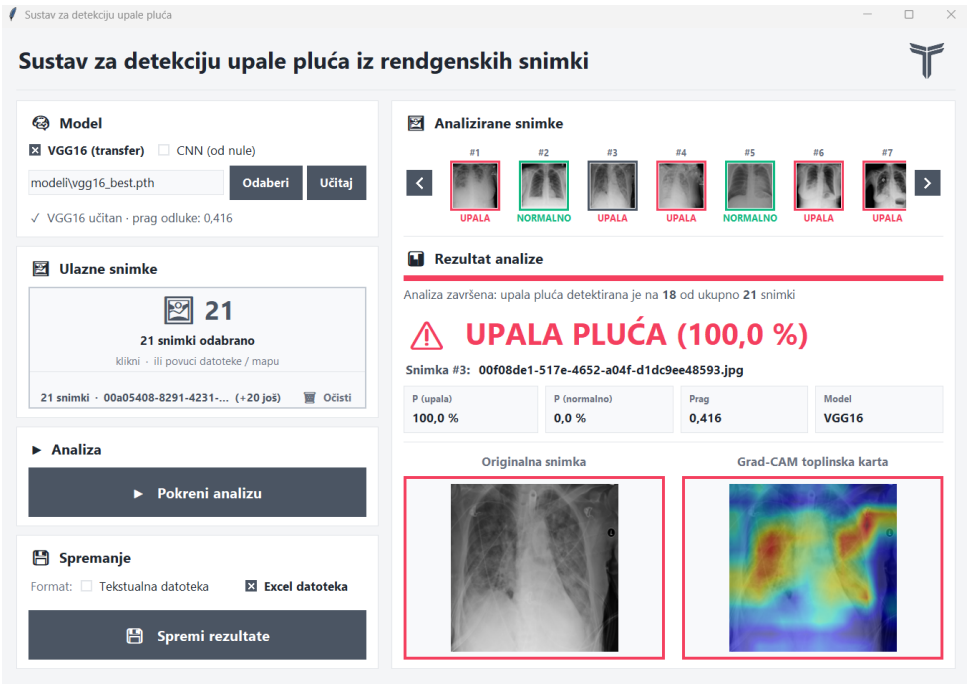
3.5. Aplikacija i *Grad-CAM* prikaz

Grafička aplikacija omogućuje učitavanje jedne ili više snimki, odabir modela, pokretanje analize i pregled rezultata. Izgled sučelja prije pokretanja analize prikazan je na slici 3.4. Za svaku obrađenu snimku prikazuju se konačna klasa, pripadajuće vjerojatnosti za obje klase, primijenjeni prag odluke i *Grad-CAM* prikaz, kao što je vidljivo na slikama 3.5 i 3.6.

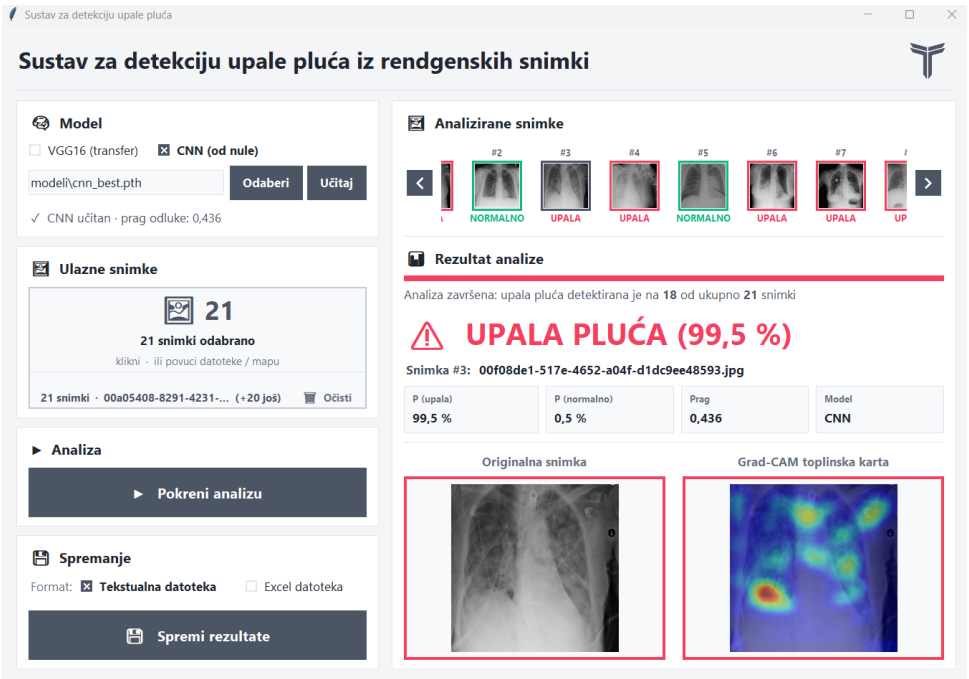
Detektirana upala pluća u sučelju je označena crvenom bojom, dok je normalan nalaz označen zelenom bojom. Pomoću *Grad-CAM* toplinske karte ističu se područja slike s najvećim utjecajem na konačnu odluku mreže, čime se korisniku pruža vizualno objašnjenje predikcije.



Slika 3.4: *Izgled aplikacije prije učitavanja modela i pokretanja analize.*



Slika 3.5: *Rezultat analize iste snimke modelom VGG16.*



Slika 3.6: *Rezultat analize iste snimke modelom CNN.*

Na prikazanom primjeru u sklopu oba modela ista snimka klasificirana je kao upala pluća s visokom razinom vjerojatnosti. U oba slučaja *Grad-CAM* toplinska karta najistaknutija područja smješta unutar plućnih polja, a ne na rubovima slike, tekstualnim oznakama ili području ramena, čime se smanjuje sumnja na ranije opisani problem učenja prečica. Pritom je kod vlastite *CNN* arhitekture fokus izraženo usmjeren na uža, jasno odvojena žarišta, dok je kod modela *VGG16* naglašeno područje šire i difuznije.

4. REZULTATI TESTIRANJA

4.1. Postupak treniranja i evaluacije

Evaluacija sustava obuhvaća usporedbu *CNN* modela treniranog od nule i modela *VGG16* s transfer učenjem. Skup za treniranje koristi se za učenje parametara mreže, validacijski skup za praćenje napretka i optimizaciju praga odluke, a testni skup za konačnu procjenu generalizacije na neviđenim snimkama. Podjela je izvedena na način da pojedine snimke ne pripadaju istovremeno različitim podskupovima, čime se sprječava precjenjivanje uspješnosti klasifikacije.

Tijekom treniranja bilježe se funkcija gubitka, odziv i specifičnost. Po završetku optimizacije generiraju se grafovi tijeka treniranja, matrica konfuzije, *ROC* krivulja (engl. *Receiver Operating Characteristic*) te pregled evaluacijskih metrika, čime se omogućuje usporedba modela i procjena njihove učinkovitosti na testnim podatcima.

4.2. Metrike evaluacije

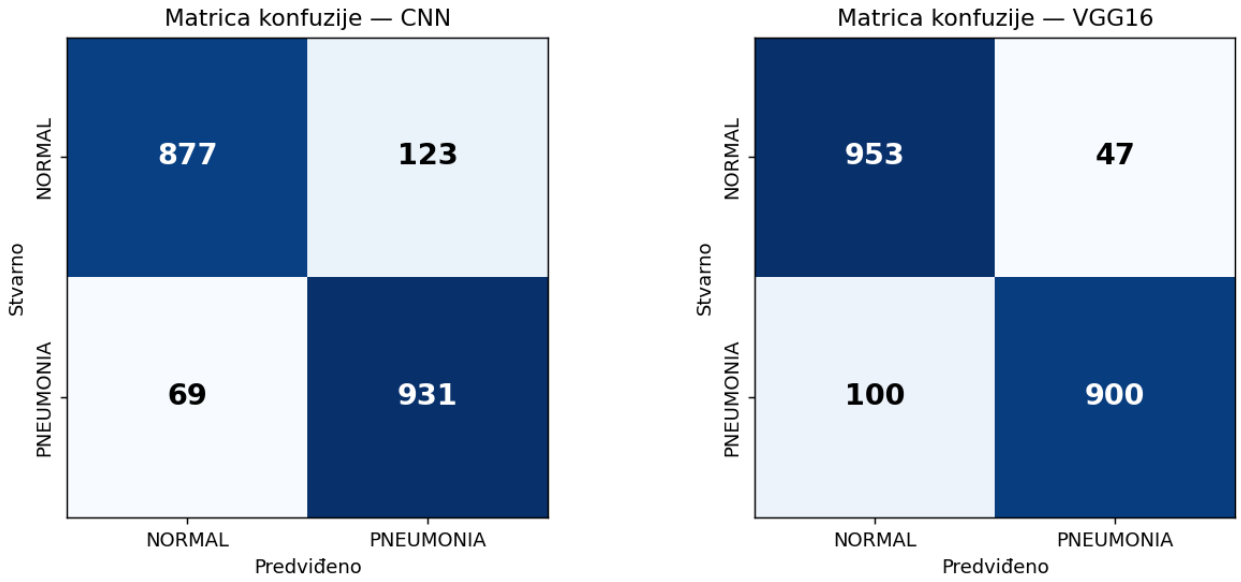
Sama točnost nije dovoljna mjera uspješnosti u medicinskoj klasifikaciji. Kod neuravnoteženih podataka visoka točnost može se postići pukim svrstavanjem većine snimki u brojniju klasu, uz izostanak prepoznavanja stvarne bolesti. Osim toga, lažno negativan rezultat klinički je znatno opasniji od lažne uzbune, zbog čega se evaluacija provodi pomoću više komplementarnih metrika:

- **Točnost** – udio svih ispravno klasificiranih snimki u ukupnom broju podataka. Pruža opću sliku uspješnosti, ali se smatra nepouzdanom u uvjetima neuravnoteženosti klasa.
- **Preciznost** – udio stvarnih slučajeva upale pluća među svim snimkama koje su označene kao pozitivne. Visoka preciznost upućuje na rijetko pogrešno označavanje normalnih nalaza kao upale pluća.
- **Odziv** ili osjetljivost – udio snimki s upalom pluća koje su ispravno prepoznate. Visok odziv rezultira malim brojem propuštenih slučajeva bolesti, što je u medicinskom kontekstu od kritične važnosti.
- **Specifičnost** – udio normalnih snimki koje su ispravno razvrstane u negativnu klasu. Visoka specifičnost osigurava da se zdravi pacijenti rijetko pogrešno identificiraju kao bolesni.
- **F1-mjera** – harmonička sredina preciznosti i odziva. Koristi se kada je potrebno istovremeno evaluirati utjecaj lažno pozitivnih i lažno negativnih rezultata.
- **AUC** (engl. *Area Under the Curve*) – površina ispod *ROC* krivulje, koja prikazuje odnos odziva i udjela lažno pozitivnih rezultata pri različitim pragovima odluke. Vrijednost *AUC* blizu 0,5 odgovara nasumičnom pogađanju, dok vrijednost blizu 1,0 označava visoku sposobnost razlikovanja normalnih snimki od snimki s upalom pluća.

Konačna odluka o klasi donosi se usporedbom izlazne vjerojatnosti modela s pragom odluke. Umjesto uobičajene vrijednosti od 0,5, prag se optimizira na validacijskom skupu pomoću Youdenova indeksa [7], pri kojem je zbroj odziva i specifičnosti maksimalan. Budući da je primarni cilj minimizacija lažno negativnih rezultata, prag se dodatno prilagođava radi zadržavanja visoke osjetljivosti.

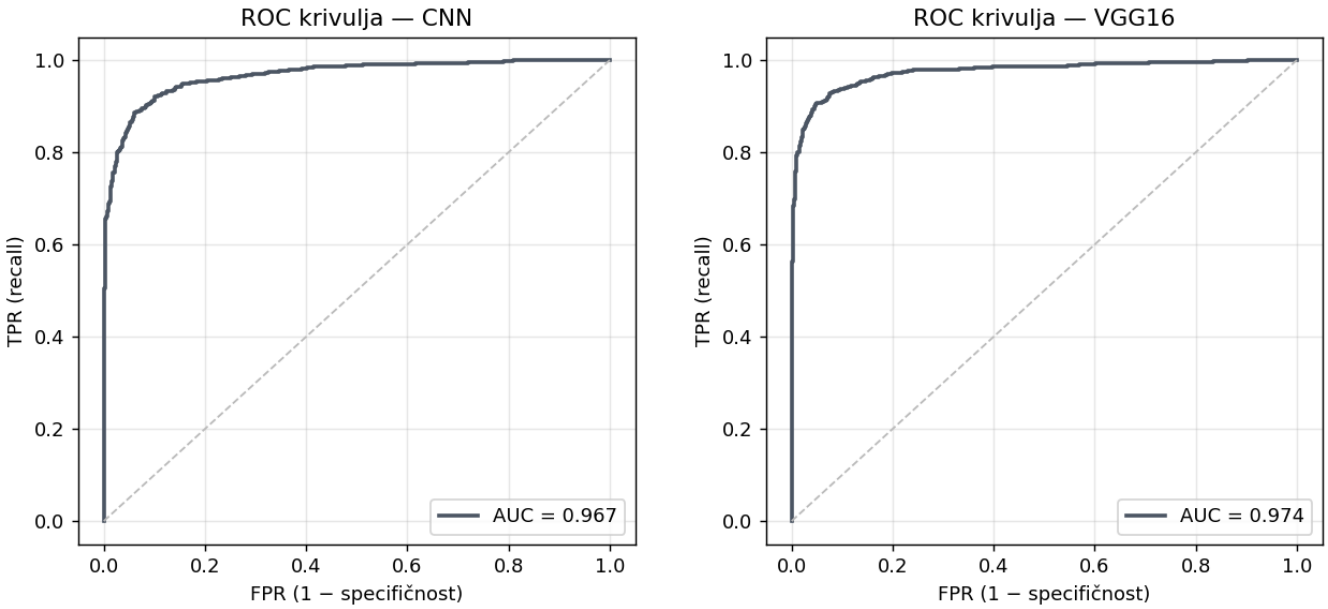
4.3. Usporedba matrica konfuzije i ROC krivulja modela

Pomoću matrice konfuzije prikazuje se broj ispravno i pogrešno klasificiranih snimki po stvarnim i predviđenim klasama. Posebna pažnja posvećuje se lažno negativnim slučajevima, u kojima se snimka s upalom pluća označava kao normalna, jer takvi ishodi predstavljaju najveći klinički rizik zbog neprepoznatih bolesti. Matrice konfuzije za oba modela prikazane su na slici 4.1.



Slika 4.1: *Matrice konfuzije za oba modela.*

Pomoću *ROC* krivulje prikazuje se odnos odziva i udjela lažno pozitivnih rezultata pri svim mogućim pragovima odluke, dok površina ispod krivulje mjeri sposobnost modela da razdvoji klase neovisno o odabranom pragu. *ROC* krivulje za oba modela prikazane su na slici 4.2.



Slika 4.2: *ROC krivulje za oba modela.*

4.4. Usporedba metrika modela

Usporedba se provodi na temelju istih metrika i identičnog testnog skupa. *CNN* model treniran od nule pokazuje mogućnost rješavanja zadatka isključivo ekstrakcijom značajki iz dostupnih rendgenskih snimki, dok model *VGG16* predstavlja komparativni pristup zasnovan na općim vizualnim strukturama. Rezultati su prikazani u tablici 4.1.

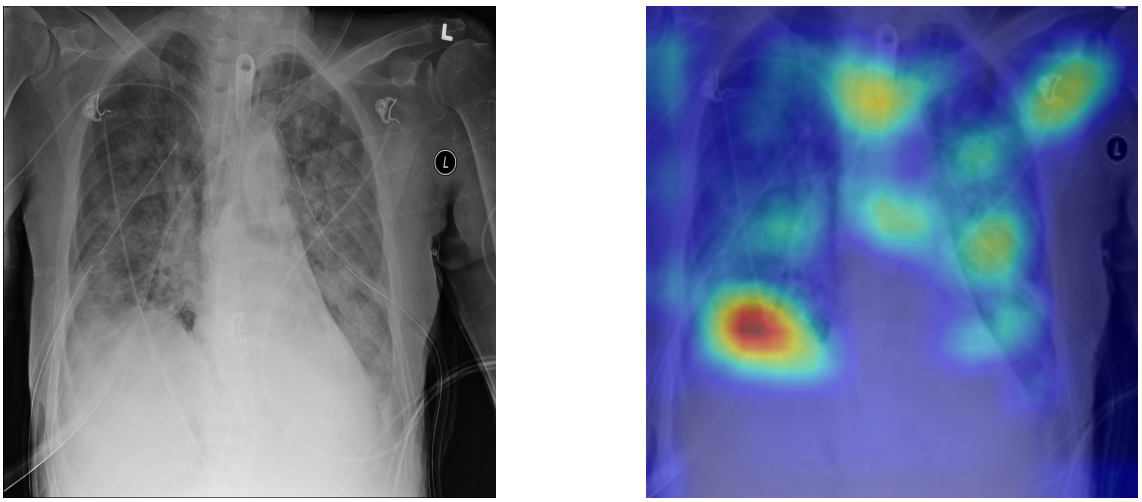
Tablica 4.1: *Usporedba rezultata CNN modela i VGG16 modela.*

Model	Prag	Točnost	Preciznost	Odziv	Specifičnost	F1	AUC
CNN od nule	0,436	90,40%	88,33%	93,10%	87,70%	90,65%	0,967
VGG16	0,416	92,65%	95,04%	90,00%	95,30%	92,45%	0,974

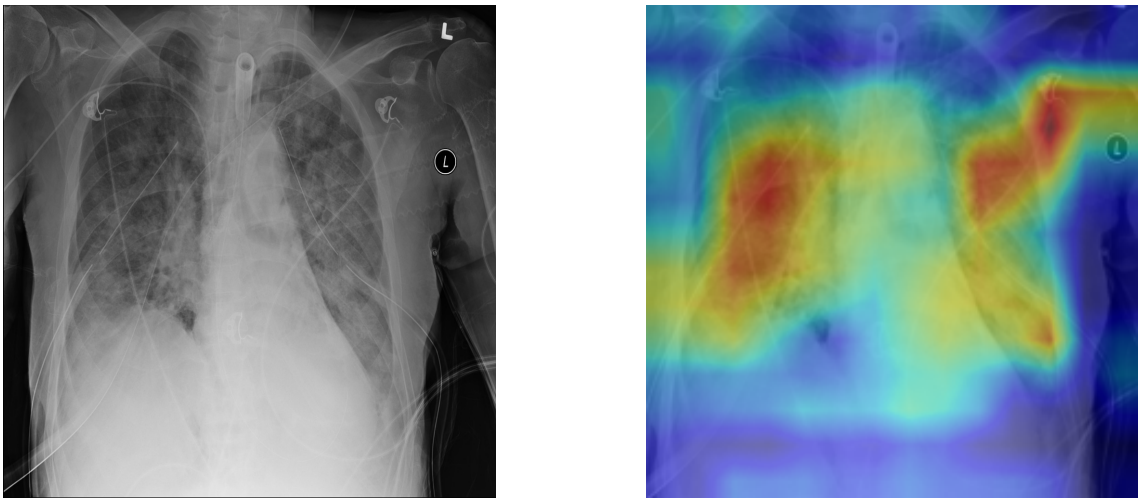
Pri interpretaciji dobivenih rezultata nije dovoljno promatrati samo ukupnu točnost. Model s većim odzivom minimizira broj propuštenih slučajeva upale pluća, dok se modelom s većom specifičnošću točnije prepoznaju normalni nalazi. Usporedba se stoga evaluira kao kompromis između visoke osjetljivosti i stope lažno pozitivnih rezultata.

4.5. Usporedba *Grad-CAM* rezultata modela

Vizualizacija *Grad-CAM* koristi se za provjeru prostornih područja slike na koja se model najviše oslanja pri donošenju odluke. Valjan rezultat ne podrazumijeva samo ispravnu klasifikaciju, nego i smisleno objašnjenje predikcije. Kada se na toplinskoj karti naglašavaju anatomske regije pluća, rezultat se interpretira kao uvjerljiviji, dok se u slučajevima kada se fokus mreže usmjerava na rubove slike, tekstualne oznake ili artefakte izvan prsnog koša, model se vjerojatno oslanja na neželjena obilježja. Primjeri *Grad-CAM* analize za oba modela prikazani su na slikama 4.3 i 4.4.



Slika 4.3: *Grad-CAM analiza vlastitog CNN modela.*



Slika 4.4: *Grad-CAM analiza modela VGG16.*

Na slici 4.3 uočava se da se u sklopu vlastitog *CNN* modela naglašava nekoliko lokaliziranih područja unutar plućnih polja, pri čemu je najizraženija regija smještena u donjem dijelu pluća. Takav prikaz upućuje na donošenje odluke na temelju užih regija, što je poželjno jer se fokus zadržava unutar anatomskog područja relevantnog za detekciju upale pluća.

Kod modela *VGG16*, prikazanog na slici 4.4, toplinskom kartom obuhvaća se znatno šire područje prsnog koša. Naglašena područja nalaze se većim dijelom unutar plućnih polja, ali su raspoređena difuznije i manje lokalizirano nego kod vlastitog *CNN* modela. Navedeni vizualni odziv upućuje na oslanjanje modela na općenitije vizualne obrasce, što se interpretira kao očekivano kod arhitekture koja koristi prethodno naučena obilježja kroz transfer učenje.

Usporedbom prikaza zaključuje se da se u sklopu obaju modela pažnja u određenoj mjeri usmjerava na relevantna područja prsnog koša, bez dominantnog oslanjanja na tekstualne oznake ili rubove slike. Ipak, kroz vlastitu *CNN* arhitekturu generira se lokaliziraniji *Grad-CAM* odziv, dok se kod modela *VGG16* uočava širi i manje precizno ograničen fokus. Zbog toga se *Grad-CAM* analiza primjenjuje isključivo kao dodatna provjera interpretabilnosti, a ne kao samostalan dokaz medicinske ispravnosti predikcije.

4.6. Ograničenja sustava

Unatoč postignutim rezultatima, potrebno je istaknuti nekoliko ograničenja sustava. Dobiveni rezultati uvjetovani su korištenim skupom podataka, njegovom raspodjelom i načinom pripreme snimki. Iako se primjenjuju predobrada, augmentacija i analiza *Grad-CAM* toplinskih karata, i dalje je prisutna mogućnost djelomičnog učenja obrazaca specifičnih za korišteni skup podataka, umjesto isključivo medicinski relevantnih obilježja. Time se može smanjiti pouzdanost pri primjeni sustava na snimkama iz drugih bolnica, uređaja ili neovisnih izvora podataka.

Dodatno ograničenje odnosi se na postupak odabira praga odluke. Nižim pragom povećava se osjetljivost i smanjuje broj lažno negativnih rezultata, što je posebno važno kod detekcije upale pluća, ali se istodobno povećava i broj lažno pozitivnih nalaza. Zbog toga se rezultati moraju evaluirati kao kompromis između odziva i specifičnosti. Metoda *Grad-CAM* pritom služi kao pomoć pri interpretaciji odluke modela, ali ne predstavlja dokaz medicinske ispravnosti predikcije. Za stvarnu kliničku primjenu sustav je potrebno dodatno validirati na većem i neovisnom skupu medicinskih snimki.

5. ZAKLJUČAK

U ovom radu razvijen je modularni sustav za detekciju upale pluća iz rendgenskih snimki prsnog koša. U sklopu sustava obuhvaćeno je učitavanje i predobrada slika, treniranje i evaluacija modela, inferencija nad novim snimkama, generiranje *Grad-CAM* toplinskih karata te prikaz rezultata kroz grafičko korisničko sučelje.

Za potrebe klasifikacije primijenjena su dva pristupa: vlastita *CNN* arhitektura trenirana od nule i model *VGG16* u sklopu transfer učenja. Time je omogućena usporedba modela koji vizualne značajke uči izravno iz dostupnih rendgenskih snimki s modelom koji koristi prethodno naučene opće vizualne strukture. Dobivenim rezultatima potvrđuje se da se u sklopu obaju pristupa mogu uspješno razlikovati normalne snimke od snimki s upalom pluća, ali uz različit odnos odziva, specifičnosti i interpretabilnosti.

Evaluacija sustava nije se temeljila samo na ukupnoj točnosti, nego i na metrikama važnima za medicinsku klasifikaciju, posebno odzivu, specifičnosti, F1-mjeri, *AUC* vrijednosti i matrici konfuzije. Posebna pažnja posvećena je smanjenju broja lažno negativnih rezultata, budući da pogrešno označavanje snimke s upalom pluća kao normalne predstavlja najveći klinički rizik.

Analizom *Grad-CAM* toplinskih karata dodatno je provjereno na koja se područja slike modeli oslanjaju pri donošenju odluke. Kroz vlastiti *CNN* model generira se lokaliziraniji fokus unutar plućnih polja, dok se kod modela *VGG16* naglašava šire i difuznije područje prsnog koša. U oba slučaja fokus se većim dijelom zadržava na relevantnim regijama, bez dominantnog oslanjanja na tekstualne oznake ili rubove slike.

Unatoč postignutim rezultatima, sustav nije namijenjen kao samostalan dijagnostički alat. Generirani rezultati uvjetovani su korištenim skupom podataka, načinom pripreme snimki i odabranim pragom odluke, zbog čega je za stvarnu kliničku primjenu nužna dodatna validacija na većim i neovisnim medicinskim skupovima podataka. Budući razvoj mogao bi uključivati usporedbu s dodatnim arhitekturama, proširenje skupa podataka i daljnju optimizaciju praga odluke radi povećanja robusnosti i pouzdanosti sustava.

LITERATURA

[1] R. Geirhos, J.-H. Jacobsen, C. Michaelis, R. Zemel, W. Brendel, M. Bethge, F. A. Wichmann, "Shortcut Learning in Deep Neural Networks," Dostupno na: https://arxiv.org/abs/2004.07780, 2020, pristup: 11.6.2026.

[2] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, L. Fei-Fei, "ImageNet: A Large-Scale Hierarchical Image Database," Dostupno na: https://www.image-net.org/static_files/papers/imagenet_cvpr09.pdf, 2009, pristup: 11.6.2026.

[3] K. Simonyan, A. Zisserman, "Very Deep Convolutional Networks for Large-Scale Image Recognition," Dostupno na: https://arxiv.org/abs/1409.1556, 2015, pristup: 11.6.2026.

[4] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, D. Batra, "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization," Dostupno na: https://arxiv.org/abs/1610.02391, 2017, pristup: 11.6.2026.

[5] J. Hu, L. Shen, G. Sun, "Squeeze-and-Excitation Networks," Dostupno na: https://arxiv.org/abs/1709.01507, 2018, pristup: 11.6.2026.

[6] Radiological Society of North America, "RSNA Pneumonia Detection Challenge," Dostupno na: https://www.kaggle.com/c/rsna-pneumonia-detection-challenge, 2018, pristup: 11.6.2026.

[7] W. J. Youden, "Index for Rating Diagnostic Tests," *Cancer*, vol. 3, no. 1, str. 32–35, 1950. Dostupno na: https://doi.org/10.1002/1097-0142(1950)3:1<32::AID-CNCR2820030106>3.0.CO;2-3, pristup: 11.6.2026.